



AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE

WYDZIAŁ INFORMATYKI, ELEKTRONIKI I TELEKOMUNIKACJI

KATEDRA INFORMATYKI

PRACA DYPLOMOWA MAGISTERSKA

Falls prediction using deep learning time series analysis techniques

Przewidywanie zasłabnięć używając technik analizy szeregów czasowych i głębokich sieci neuronowych

Autor:	<i>inż. Maciej Błaszczuk</i>
Kierunek studiów:	<i>Informatyka</i>
Opiekun pracy:	<i>dr inż. Maciej Wielgosz</i>

Kraków, 2020

Uprzedzony o odpowiedzialności karnej na podstawie art. 115 ust. 1 i 2 ustawy z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (t.j. Dz.U. z 2006 r. Nr 90, poz. 631 z późn. zm.): „Kto przywłaszcza sobie autorstwo albo wprowadza w błąd co do autorstwa całości lub części cudzego utworu albo artystycznego wykonania, podlega grzywnie, karze ograniczenia wolności albo pozbawienia wolności do lat 3. Tej samej karze podlega, kto rozpowszechnia bez podania nazwiska lub pseudonimu twórcy cudzy utwór w wersji oryginalnej albo w postaci opracowania, artystyczne wykonanie albo publicznie zniekształca taki utwór, artystyczne wykonanie, fonogram, wideogram lub nadanie.”, a także uprzedzony o odpowiedzialności dyscyplinarnej na podstawie art. 211 ust. 1 ustawy z dnia 27 lipca 2005 r. Prawo o szkolnictwie wyższym (t.j. Dz. U. z 2012 r. poz. 572, z późn. zm.) „Za naruszenie przepisów obowiązujących w uczelni oraz za czyny uchybiające godności studenta student ponosi odpowiedzialność dyscyplinarną przed komisją dyscyplinarną albo przed sądem koleżeńskim samorządu studenckiego, zwanym dalej „sądem koleżeńskim”, oświadczam, że niniejszą pracę dyplomową wykonałem(-am) osobiście i samodzielnie i że nie korzystałem(-am) ze źródeł innych niż wymienione w pracy.

.....

Pragnę złożyć serdeczne podziękowania moim rodzicom za udzielone wsparcie. Wyrazy uznania również należą się Agacie za wiarę, motywację oraz pomoc w zakresie poprawności lingwistycznej.

Składam szczególne podziękowania mojemu Promotorowi, dr inż. Maciejowi Wielgoszowi za życzliwość, cenne uwagi merytoryczne, wszechstronną pomoc oraz poświęcony czas.

Contents

1	Introduction	7
1.1	Goals	7
1.2	Scope	8
2	State Of The Art	9
3	Dataset	10
4	Background	11
4.1	Neural Network Layers	11
4.1.1	Dense	11
4.1.2	Convolution	11
4.1.3	Long-Short Term Memory	11
4.1.4	Attention	12
4.2	Network Architectures	12
4.2.1	AutoEncoder	12
4.2.2	Variational AutoEncoder	12
5	Experimental Setup	13
6	Results	14
7	Conclusions	15
	List of Figures	16
	List of Algorithms	16

Introduction

Nowadays, deep learning is applied in many areas of life. A lot of companies compete to create the best artificial intelligence model specialized in specific tasks. Fields of study where deep learning is developing the fastest are image and text/speech processing. In this way, problems such as image recognition, image captioning, text translation or understanding speech are the matter of utilizing appropriate model prepared by specialists. It's very convenient, because crafting such a model is very demanding task and require a lot of data and computational power, which is usually not available to average people.

Health is important to everyone. Many technological advances help save people's health and lives. It is no different with deep learning. Detecting malicious tumors on X-rays is successfully used for many years. Basic life functions are simply series of data in time that can be freely monitored by artificial intelligence models. This allows to effectively detect health and life hazards in real time.

1.1 Goals

[illegible]

1.2 Scope

This document is divided into a few main parts, as following:

1. **Introduction**

Briefly discusses the topic, describes assumed goals and explains why this work is important.

2. **State Of The Art**

Presents papers discussing latest achievements in similar fields of study.

3. **Background**

Describes the data, explains utilized deep learning algorithms in depth, outlines used frameworks and libraries.

4. **Experiments**

Presents experimental setup, testing methodology and the way experiments were carried out.

5. **Results**

Explains the results obtained from experiments extensively.

6. **Conclusions**

Presents conclusions drawn from experiments' analyzes and proposes future work.

State Of The Art

Dataset

Background

This chapter presents the theoretical background behind the architecture of deep learning models used in this work. First of all the basic units that compose the neural network are described. Then there is an explanation of the whole architecture of the chosen deep learning models.

4.1 Neural Network Layers

There are many types of neural networks' layers, each of which performs different mathematical operations, which allows it to specialize in specific tasks. When building a neural network, you can stack different layers on each other, which allows you to build an infinite number of different models. This section describes selected layers that were used in this work to build the models .

4.1.1 Dense

Dense layers are super easy pro layers

4.1.2 Convolution

Convolution layers catch local patterns

4.1.3 Long-Short Term Memory

LSTM layers are better than recurrent layers

4.1.4 Attention

Attention layer helps to focus on proper features

4.2 Neural Network Architectures

To successfully perform a specified task, the model requires a properly selected architecture. Every year, more and more complicated schemes are created in order to solve more sophisticated tasks. Usually to obtain satisfactory results, a well known scheme should be followed while building a model. This subsection describes the schemes of neural network architectures used in this work.

4.2.1 AutoEncoder

AutoEncoder is unsupervised network.

4.2.2 Variational AutoEncoder

VAE is generative network.

Experimental Setup

Results

Conclusions

List of Figures

List of Algorithms

Bibliography

- [1] Qin Y., Song D., Chen H., Cheng W., Jiang G., Cottrell G.W.: A Dual-Stage Attention-Based Recurrent Neural Network for Time Series Prediction. In: *CoRR*, vol. abs/1704.02971, 2017. URL <http://arxiv.org/abs/1704.02971>.